Classificação de questões jurídicas com publicação seletiva: relatório técnico

Gabriel J. Duarte

[1]Case IA — Método VDE

gabrieljduarte98@gmail.com

a) O sistema, peça por peça

Resolvi o problema em camadas. Cada camada tem uma função simples; a tabela resume e o diagrama mostra o caminho de uma questão.

Tabela 1. O que o sistema faz

Etapa	Para que serve
Limpeza do texto	tira HTML e letras trocadas
Árvore de temas	funde 12 nós duplicados; prevejo só o nível 1
Vetores de texto (embeddings)	o Qwen3-Embedding só converte cada texto em números, uma vez, antes; não escolhe tema
Roteador por área	regressão logística minha sobre esses vetores decide a área
3 leitores (NB, BM25, LSA); nas áreas novas, BM25 e regressão logística sobre os vetores	dão opiniões independentes
Consenso + estabilidade	publica só se os leitores concordam
Calibração	transforma o escore em probabilidade

Concluo que prefiro não publicar a publicar errado.

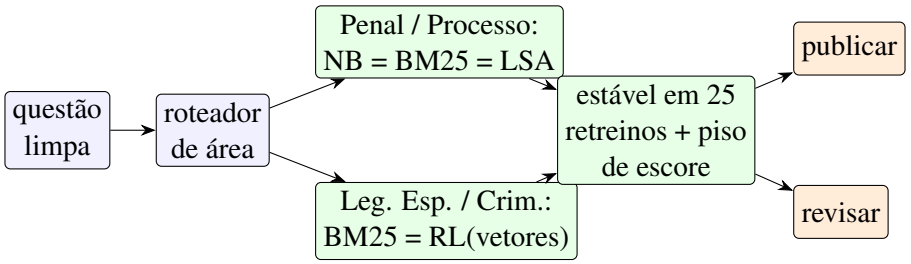

Arquitetura final: nada aqui chama modelo de linguagem.

Por que cada peça. Limpei o texto (Q0099 vinha com HTML do Word; duas tinham letras cirílicas). O case pede o tema central de cada questão (um `tema_id` de `temas.csv`, de qualquer nível; não exige o nível 2). Publico só no nível 1 porque a régua aceita pai ou filho como certo (39 das 92 da folha têm gabarito em subtema, e o tema-pai conta como acerto) e errar entre irmãos é o erro caro; o custo é que quem estuda direto um subtema não vê a questão. Três leitores (Naive Bayes hierárquico, NB; busca BM25; análise semântica latente, LSA) erram de formas diferentes, então só publico quando os três coincidem. Repito o treino 25 vezes e descarto o que muda de resposta, e corto o quarto inferior do escore. Nas áreas novas, o segundo leitor (além do BM25) é uma regressão logística minha, que lê os vetores pré-calculados pelo Qwen3-Embedding; o Qwen não escolhe nada. O roteador é outra regressão logística sobre esses vetores (acerta a área em 82%); antes dele, Legislação Especial e Criminologia tinham 0 publicadas.

Onde entra (e onde não entra) modelo de linguagem. (i) O Claude Sonnet gerou sintéticos e descrições só da árvore e da lei, sem ver as questões; ficaram como dado (`prompts/`), passaram por filtro automático e revisei uma amostra de 30 (todos coerentes), e servem só de treino da regressão logística da versão por área, com a folha. (ii) O Qwen3-Embedding só transforma texto em vetor, na preparação (`scripts/embeddings.py`; cache em `cache/embeddings/qwen/`); não gera texto nem vê os temas. (iii) Decidem minhas regressões e regras de consenso; o `replicar.sh` roda offline, sem modelo de linguagem. (iv) Como extra, fora do que o case pede, deixei uma API em que o embedding é uma etapa à parte (`/ingerir`) antes de `/classificar`, que nunca chama modelo de linguagem. (v) Sem rede neural: a versão *consenso estável* (`S4`, 78 publicadas, 0,937; ver anexo).

O que testei e descartei.

Tabela 2. O que testei e não usei

Tentativa	Resultado	Por que saiu
Outras arquiteturas (GCN, BiGRU, TextCNN, MLP, árvores, SAT/z3, self-training)	acerto do ramo 0,03–0,38 (NB 0,47)	poucos rótulos por tema
Outros embeddings (e5, BERT jurídico) como voto	abaixo do NB	pior como voto (0,91)
Exemplos sintéticos	NB +4 pontos	consenso caiu a 0,82–0,90
Detector de fora	AUC 0,33–0,49	não separa nada
Um-contra-o-resto por tema	0,9375, 55 publ.	barrou 85% das normais
Corpus da OAB	LSA 0,47 para 0,40	piorou
Limiar das versões originais	0,957 e 0,983	vazava; real 0,884 e 0,91

Concluo que o ganho veio de exigir concordância e medir sem vazamento, não de modelos sofisticados.

b) Os 100 rótulos

Usei validação cruzada: divido as 100 questões em 5 partes, treino com 4, testo na quinta até cada parte ser teste uma vez, e repito 5 vezes embaralhando; cada questão é testada por um modelo que não a viu. Usei os rótulos para treino (o NB aprende com as 92 que não são `fora`), calibração (converto o escore em probabilidade só com questões fora da parte de teste) e teste (conto os acertos nas partes de teste). Não separei um conjunto de teste fixo (20 questões seriam pouco); como escolher a configuração nas mesmas questões vicia o resultado, calculei também um limite aninhado (0,94; ver anexo).

Tabela 3. Resultado

Versão	Precisão	Publicadas de 559
Inicial: limiar calibrado (declarava 0,957)	0,884	171
Consenso estável (`S4`)	0,937	78
Consenso estável por área (`A1`, entrega; previsão 0,94)	0,958	103

Concluo que perdi publicações (171 para 103) para ganhar uma precisão que posso defender.

Por que prevejo 0,94 se a validação deu 0,958? Publico só cerca de 24 questões distintas por repetição, o que é pouco; a correção de Jeffreys desconta isso para não

prometer mais do que os dados sustentam: com o único erro na Q0043, $(22{,}6+\frac{1}{2})/(23{,}6+1) \approx 0{,}94$.

Os rótulos mostraram que a Q0043, marcada `fora`, trata de dosimetria (tema que existe na árvore), e que, com lei especial citada mas foco no instituto, a equipe usa o tema geral.

c) Diagnóstico

O que ainda erra. (i) Questões `fora` que parecem normais, como a Q0043: sempre devolvo um tema. (ii) Pares de irmãos quase iguais (Provas em Espécie/Espécies; Recursos). (iii) Concursos novos: um classificador separa novas de banco com AUC 0,83, então a precisão nelas não é mensurável sem rótulos.

O terceiro rótulo, `fora`. Não emito `fora`. O detector não teve sinal (AUC 0,33–0,49, 8 exemplos) e o um-contra-o-resto recusou 95% das `fora` e 85% das normais. Como apagar uma questão boa custa mais que revisá-la, a dúvida vai para `revisar` com tema sugerido; a marca `fora` do professor na fila vira rótulo para o detector.

O que resolveria cada um. (i) Revisar os rótulos `fora` e criar os nós que faltam. (ii) Fundir ou definir a fronteira entre os irmãos. (iii) Rotular 200–300 questões novas.

Por que duas áreas tinham 0 publicadas. As questões novas não trazem a disciplina de Legislação Especial, e o primeiro estágio as mandava a Penal; Criminologia tem só 10 rótulos. O roteador de texto corrigiu isso (Leg. Especial 22 e Criminologia 4 publicadas), mas nasceu de ver essa falha, então a estimativa nessas áreas é otimista.

d) Produção

Custo e tempo. Tudo roda em CPU, sem GPU e sem API paga; as 659 levam cerca de 3,5 min com treino e validação. Medi uma questão por vez, com 8 threads: gerar o vetor leva 1,0 s e classificar 0,11 s; para 50 mil questões por semana, cerca de 16 h de CPU num servidor comum. Num núcleo só seriam cerca de 30 h; com mais núcleos ou máquinas em paralelo, o tempo cai. Com 18% de cobertura, cerca de 9 mil seriam publicadas e 41 mil iriam para a fila; o custo real é o tempo do professor.

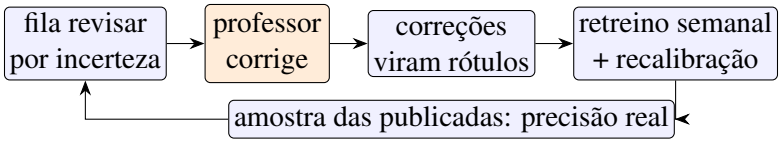

Correção vira dado. Ordeno a fila `revisar` pela incerteza do consenso e do retreino (aprendizado ativo; Settles, 2009): o professor não lê as 41 mil, só as mais informativas. Estimo (não medi): 500 por semana, a uns 30 s cada, são cerca de 4 h dele e 5 vezes a folha atual, o bastante para medir a precisão nas áreas com 10–12 rótulos. Cada correção entra na folha de treino. **Retreino semanal** (minutos), com recalibração; toda semana confiro uma amostra aleatória das publicadas para medir a precisão real.

O que faria com mais tempo

Com mais tempo, eu (1) poria o aprendizado ativo da seção d) para rodar; (2) montaria um RAG offline com um modelo gratuito (GLM-4.7-Flash, Z.ai), *só antes da decisão*, para escrever descrições e exemplos revisados e guardados como dado; (3) rotularia mais `fora`; (4) desceria ao subtema só quando a lei e o artigo citados apontam um subtema único.

Referências. Brown, Cai e DasGupta, *Statistical Science* 16(2), 2001. Varma e Simon, *BMC Bioinformatics* 7:91, 2006. Cawley e Talbot, *JMLR* 11, 2010. Settles, *Active Learning Literature Survey*, 2009.

e) Memo para o professor

Assunto: o que encontrei e o que peço ao senhor.

Professor, construí um programa que lê cada questão e sugere um tema da árvore. Ele só publica sozinho quando várias leituras independentes apontam o mesmo tema; o resto chega ao senhor em fila, com uma sugestão, e basta confirmar ou trocar.

O que encontrei. Testei o programa cinco vezes nas 100 questões que sua equipe classificou, sempre escondendo dele a resposta: das questões que ele publicou, errou uma só, a Q0043, que a planilha marca como `fora`. Em produção, publico 103 de 559 questões (18%); espero acertar cerca de 94% delas. Não consigo garantir os 95% nas questões novas, porque não há rótulos para medi-las.

O que recomendo mudar nos temas.

- Fundir os nós repetidos (as duas "Partes" de Administração Pública, Patrimônio, Teoria da Pena, Competência e Sentença; "Provas em Espécie" e "Espécies"; os Recursos). Eles confundem o sistema e o aluno.
- Dizer se são intercambiáveis: Punibilidade e Prescrição; Organizações Criminosas e Lavagem de Dinheiro.
- Rever a Q0043 (fixação da pena) e as marcadas `fora`, como a Q0017 e a Q0303, e criar os temas que faltam.

Do que preciso do senhor.

1. Peço que o senhor reveja os rótulos `fora` citados acima.
2. Peço de 200 a 300 questões novas classificadas (Q0360 em diante), 30 a 50 só de Criminologia e de Legislação Especial.
3. Peço que me diga a regra: lei especial citada, mas foco no instituto, vale o tema geral?
4. Revisei 30 exemplos sintéticos sorteados e todos fazem sentido; peço que o senhor confira mais alguns por amostragem.

Como a correção do senhor volta ao sistema. Cada confirmação ou troca vira uma questão classificada no treino da semana seguinte. As marcadas "fora da árvore" viram a lista de temas a criar, e toda semana confiro uma amostra do que publiquei para medir o acerto real.